Trabajo Práctico Integrador

Expensa House: **desarrollo de una aplicación con inteligencia artificial**

Estudiante: **Griselda Blanco**

Tema: **Modelos de Hugging Face aplicados a la comparación de productos**

Contenido

1. Introducción 2
2. Problema que se busca resolver 3
   Objetivos del trabajo 3
3. Arquitectura y tecnologías utilizadas 4
4. Gestión del inventario y sincronización 5
5.1. Búsqueda semántica de ofertas mediante E5 5
Marco conceptual: 6
5.2. Detección de intenciones 6
5.3. Modelo integrado: multilingual-e5-small 7
5.4. Pruebas y resultados obtenidos 7
5.5. Reconocimiento de voz con Whisper 8
5.6. Asistente Boti House 8
6. Análisis exploratorio de datos (EDA) 8
Problemas técnicos y solución adoptada 9
Estado de otras funcionalidades 9
Análisis de la experiencia 9
Próximos pasos y propuestas de mejora 10
Conclusión 10

Fuentes y herramientas mencionadas 10
7. Limitaciones y mejoras futuras 11
8. Enlaces de entrega 11

1. Introducción

Expensa House es un proyecto orientado a facilitar la administración de los gastos y productos del hogar mediante una aplicación Android, una interfaz web y componentes de inteligencia artificial. La propuesta surge de una necesidad cotidiana: controlar los productos disponibles, anticipar las reposiciones, organizar las compras y administrar mejor el presupuesto familiar.

El desarrollo combina tecnologías de programación móvil y web, almacenamiento de datos, visualización de información y modelos de inteligencia artificial previamente entrenados. El objetivo es construir una solución que permita consultar información del hogar, comparar ofertas cargadas en el sistema y explorar patrones de compra y consumo.

El proyecto también permite aplicar conocimientos de ciencia de datos e inteligencia artificial, especialmente en la utilización de modelos existentes para resolver tareas concretas mediante inferencia, sin necesidad de entrenar un modelo desde cero.

Para abordar esta necesidad, se exploraron modelos disponibles en Hugging Face capaces de comparar la similitud entre textos. El trabajo se centró en analizar alternativas livianas, revisar sus resultados en una muestra de consultas e integrar el modelo multilingual-e5-small en el flujo de búsqueda de la aplicación.Describe el proceso de selección, la forma en que se utilizó el modelo, los resultados reportados, los problemas encontrados y las mejoras que podrían realizarse. Es importante aclarar que la evaluación disponible corresponde a una muestra pequeña de 11 consultas de demostración, por lo que sus resultados son preliminares.

2. Problema que se busca resolver

La administración de una despensa familiar puede resultar difícil cuando no existe un registro actualizado de los productos, sus cantidades, los artículos que están en uso y los gastos realizados. Esta situación puede provocar compras innecesarias, falta de productos esenciales y dificultades para controlar el presupuesto mensual.

Expensa House busca centralizar esta información y ofrecer herramientas para facilitar la toma de decisiones. Entre sus objetivos se encuentran identificar productos con stock crítico, mantener una lista de compras, registrar gastos y comparar precios de ofertas almacenadas.

La solución incorpora un enfoque de inteligencia artificial para explorar búsquedas por similitud semántica y facilitar la interpretación de consultas expresadas en lenguaje natural. De esta manera, el sistema busca ir más allá de una búsqueda literal basada únicamente en palabras coincidentes.

Objetivos del trabajo

Objetivo general. Analizar la utilidad de modelos de inteligencia artificial para mejorar la búsqueda y comparación semántica de productos en Expensa House.

Objetivos específicos. Explorar modelos en Hugging Face; comparar la búsqueda literal con MiniLM y E5 small; describir la integración de multilingual-e5-small; identificar errores de clasificación; documentar dificultades técnicas; y proponer mejoras para futuras evaluaciones.

3. Arquitectura y tecnologías utilizadas

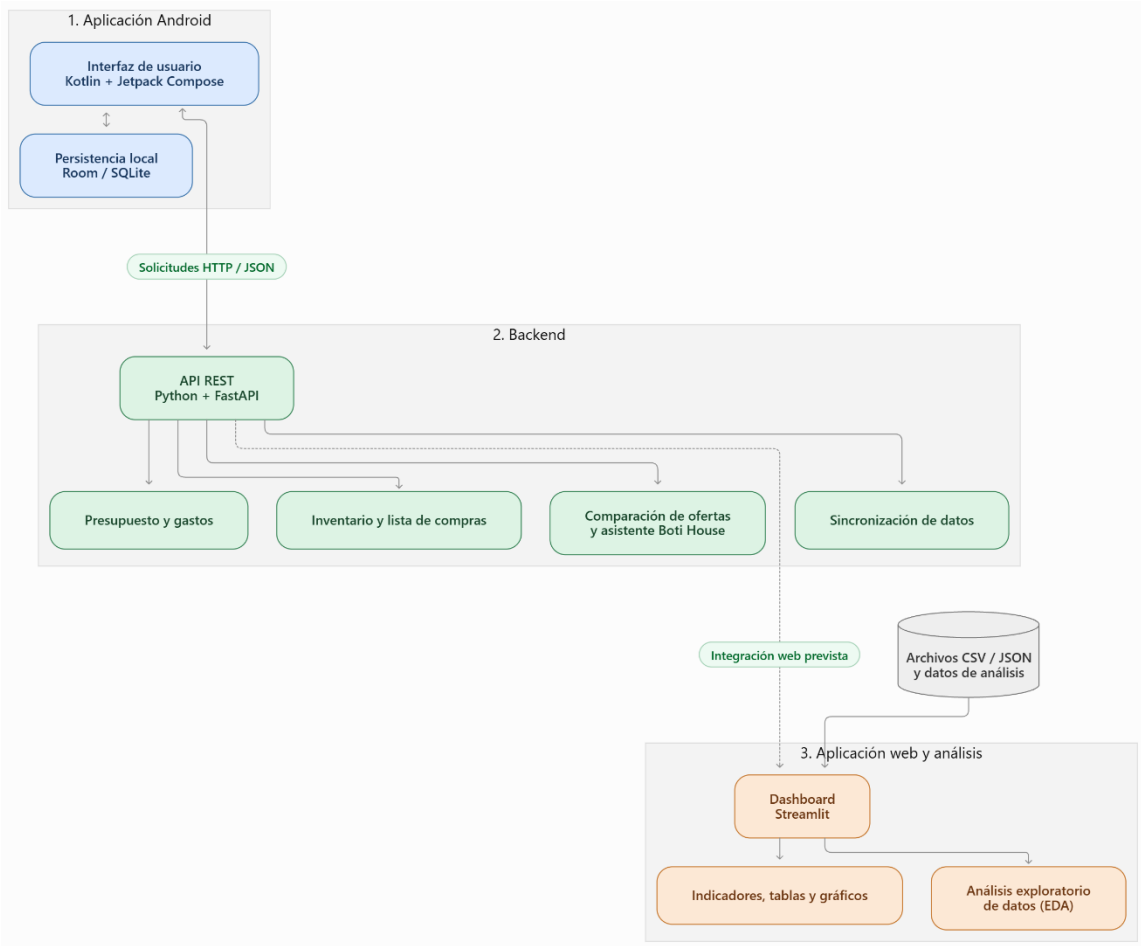


Figura 1. Arquitectura funcional de Expensa House.

La arquitectura de Expensa House se divide en tres componentes principales. La aplicación Android, desarrollada con Kotlin y Jetpack Compose, permite gestionar el inventario, las compras y la información del hogar. La persistencia local se plantea mediante Room, basada en SQLite.

El backend, desarrollado en Python con FastAPI, expone una API REST que permite consultar y modificar información del inventario, la lista de compras, el presupuesto y los gastos. También incluye operaciones para comparar ofertas, procesar consultas de Boti House y sincronizar información.

Por último, la aplicación web, desarrollada con Streamlit, permite visualizar indicadores, tablas y gráficos, además de realizar análisis exploratorio de datos (EDA). En la versión del código revisado, parte de esta información se obtiene de archivos CSV y JSON. La integración directa entre el dashboard y la API debe verificarse o completarse para garantizar que ambos componentes trabajen con los mismos datos.

4. Gestión del inventario y sincronización

El inventario diferencia entre unidades cerradas disponibles y unidades que ya están en uso. Esta distinción permite representar mejor el estado real de los productos del hogar.

El backend contempla operaciones para agregar, actualizar y eliminar productos, abrir una unidad y registrar su consumo. También permite administrar artículos de la lista de compras y trasladarlos al inventario cuando corresponde.

La sincronización entre Android y la web se implementa mediante una API. El endpoint GET /api/sync devuelve el estado compartido, mientras que POST /api/sync recibe una instantánea de los datos enviados por la aplicación Android y actualiza la información almacenada en el backend.

Este mecanismo permite compartir información entre ambos componentes. Sin embargo, la implementación descrita corresponde a una sincronización mediante solicitudes: no implica actualización automática en tiempo real. La visualización web puede requerir una nueva consulta o una actualización de la página.

5. Inteligencia artificial aplicada al proyecto

5.1. Búsqueda semántica de ofertas mediante E5

Para comparar ofertas se utiliza el modelo intfloat/multilingual-e5-small, que genera representaciones vectoriales de textos. Estas representaciones permiten calcular similitudes entre consultas y descripciones de productos.

El código combina dos estrategias. Primero, aplica un filtro conservador de coincidencia de palabras clave para reducir el riesgo de comparar productos diferentes. Después, utiliza la similitud semántica E5 para ordenar las ofertas candidatas.

Este enfoque busca equilibrar flexibilidad y precisión. Por ejemplo, una consulta puede expresarse con palabras distintas de las utilizadas en el nombre de un producto. La representación semántica puede ayudar a encontrar relaciones

entre textos, mientras que el filtro de palabras clave limita comparaciones poco confiables.

El sistema también consulta el inventario para generar una advertencia cuando el producto tiene pocas unidades cerradas. Así, la comparación de ofertas puede acompañarse de información útil para decidir si conviene reponer un artículo.

Una limitación importante es que el sistema trabaja con ofertas guardadas manualmente. El código no demuestra que consulte automáticamente los precios actuales de los supermercados. Por lo tanto, no se puede garantizar la vigencia de los precios ni determinar el precio real por kilogramo o litro si no se registran los datos necesarios.

Marco conceptual: búsqueda semántica y embeddings

La búsqueda literal compara palabras o fragmentos de texto. Puede ser útil cuando las descripciones coinciden, pero presenta limitaciones si se usan sinónimos, distintas formas de escribir el producto o descripciones alternativas. La búsqueda semántica intenta estimar qué tan relacionados están dos textos por su significado. El modelo multilingual-e5-small genera embeddings, es decir, representaciones numéricas de los textos que permiten calcular una medida de similitud. De este modo, dos descripciones que no son idénticas pueden obtener una puntuación alta si expresan conceptos parecidos. La similitud semántica no garantiza que dos productos sean equivalentes comercialmente. Productos de la misma categoría, pero con atributos diferentes —como aceite de oliva y aceite de girasol— pueden compartir vocabulario. Por eso, el resultado del modelo debe combinarse con reglas de negocio y validaciones específicas.

5.2. Detección de intenciones

El proyecto incorpora una función experimental de detección de intenciones basada también en E5. Su objetivo es clasificar consultas del usuario en tres categorías:

- Reposición: preguntas sobre productos que se están terminando o que faltan comprar.
- Ofertas: consultas relacionadas con promociones y precios.
- Presupuesto: preguntas sobre gastos y dinero disponible.

La función compara el mensaje con ejemplos asociados a cada intención y selecciona la categoría con mayor similitud. Para aceptar una intención, se utiliza un umbral configurado en 0.88.

El proyecto incluye un script de calibración que evalúa frases positivas —que deberían clasificarse en alguna categoría— y frases negativas —que no deberían activar ninguna intención—. Esta prueba permite estudiar falsos positivos y falsos negativos y ajustar el umbral.

El valor 0.88 es una configuración experimental, no una garantía de precisión. Para justificar su elección en el informe, conviene presentar los resultados obtenidos con las mismas frases de prueba y explicar qué errores se observaron.

5.3. Modelo integrado: multilingual-e5-small

El modelo integrado es multilingual-e5-small. Su función en la aplicación es puntuar y ordenar ofertas que ya pasaron un filtro inicial de palabras clave. El flujo descrito comienza con la consulta de la persona usuaria; luego se aplica el filtro para reducir el conjunto de ofertas; E5 calcula la similitud de las candidatas y finalmente se ordenan los resultados.

La presentación indica que el modelo se descarga en el primer uso y se ejecuta localmente mediante Transformers, sin necesitar un token de inferencia remota. También indica que trabaja con las ofertas manuales sincronizadas con la aplicación.

5.4. Pruebas y resultados obtenidos

La evaluación informada se realizó sobre 11 consultas de demostración. Los resultados reportados fueron los siguientes:

Método	Aciertos	Porcentaje aproximado
Búsqueda literal	1 de 11	9 %
MiniLM multilingüe	7 de 11	64 %
E5 small	8 de 11	73 %

En esta prueba, E5 obtuvo el mayor número de aciertos. Sin embargo, la presentación señala que también clasificó como coincidencias los tres casos negativos evaluados. MiniLM mostró menos falsos positivos, pero más falsos negativos. La cantidad reducida de consultas impide establecer una conclusión definitiva sobre el rendimiento general de los modelos.

5.5. Reconocimiento de voz con Whisper

El backend contempla una alternativa de reconocimiento automático de voz mediante el modelo openai/whisper-tiny, utilizando la biblioteca Transformers. El código permite intentar la transcripción en español y, si Whisper falla, recurrir a una alternativa basada en el reconocimiento de voz de Google.

Esta funcionalidad depende de una variable de configuración que habilita Whisper. Por lo tanto, que el endpoint esté programado no demuestra por sí solo que Whisper esté activo en todos los entornos ni que la integración esté desplegada y operativa en la versión pública de la aplicación.

5.6. Asistente Boti House

Boti House permite realizar consultas sobre reposición, ofertas guardadas y presupuesto. En el código del backend, las respuestas se construyen principalmente a partir de reglas que identifican palabras o expresiones relacionadas con cada tema y consultan los datos almacenados.

La detección semántica E5 puede utilizarse como mecanismo adicional cuando está habilitada. Es importante distinguir este funcionamiento de un chatbot generativo basado en un modelo de lenguaje: el código compartido no demuestra que Boti House genere sus respuestas mediante un modelo generativo.

siguientes: Método Aciertos Porcentaje aproximado Búsqueda literal 1 de 11-> 9 % MiniLM multilingüe E5 small 7 de 11 y 8 de 11-> 64 % y 73 %

6. Análisis exploratorio de datos (EDA)

El proyecto contempla un dashboard desarrollado con Streamlit para analizar el inventario y los movimientos de compra y consumo. Entre los indicadores previstos se encuentran el gasto total estimado, la cantidad de productos distintos y el número de movimientos registrados.

El análisis se organiza alrededor de tres hipótesis:

Hipótesis 1. Categorías y reposición. Analizar qué categorías concentran la mayor frecuencia de compras para identificar los grupos de productos que requieren más atención.

Hipótesis 2. Stock crítico y presupuesto. Examinar el gasto acumulado por producto para detectar artículos con mayor impacto económico y explorar oportunidades de reposición.

Hipótesis 3. Consumo por día de la semana. Analizar cómo se distribuyen los movimientos de consumo según el día para identificar posibles patrones temporales.

Estas hipótesis pueden orientar futuras mejoras, como las alertas de reposición o la estimación del agotamiento del stock. No obstante, los gráficos por sí solos no demuestran que exista una relación predictiva: las conclusiones deben sustentarse en los datos observados.

Problemas técnicos y solución adoptada

Durante una prueba de inferencia remota mediante InferenceClient se recibió el error HTTP 402 (Payment Required), asociado a la falta de créditos disponibles. Para continuar con la implementación, se optó por ejecutar el modelo localmente con Transformers. Esta decisión evita depender de créditos de inferencia remota y de un token para esa ejecución.

Estado de otras funcionalidades

La presentación describe Whisper tiny como una alternativa futura para voz a texto. Actualmente, el dictado de la aplicación utiliza Web Speech API y reconocimiento de Google; Whisper está disponible únicamente en una demostración con Gradio y queda pendiente conectarlo a la web principal, instalar o resolver la dependencia de FFmpeg y probarlo con acento argentino. También se propone incorporar Qwen2.5 0.5B para permitir consultas en lenguaje natural sobre ofertas y módulos de la aplicación. Según el planteo, el modelo debería recibir los datos reales de la web para no inventar precios. Como alternativa más liviana, E5 podría utilizarse para detectar la intención de una consulta.

Análisis de la experiencia

La experiencia permitió recorrer distintas etapas de trabajo con modelos preentrenados: búsqueda de alternativas, comparación inicial, integración y evaluación. También permitió reconocer que elegir un modelo por su puntuación de similitud no alcanza para resolver completamente un problema de negocio. En este caso, los nombres de productos pueden ser parecidos sin que los artículos sean intercambiables. El problema de los créditos de inferencia remota fue una limitación concreta de implementación. La ejecución local con Transformers permitió continuar el trabajo sin depender de ese servicio. Por otra parte, los resultados de la muestra evidenciaron que es necesario analizar tanto los aciertos como los errores, especialmente cuando una coincidencia incorrecta puede afectar la comparación de precios. El material disponible no detalla un entrenamiento propio del modelo. Por lo tanto, el proceso se describe como selección, integración y evaluación de modelos

preentrenados, y no como entrenamiento desde cero. Tampoco se dispone del conjunto de datos completo, del código de evaluación ni de las puntuaciones individuales; esas evidencias serían necesarias para reproducir el experimento con precisión.

Próximos pasos y propuestas de mejora

Para fortalecer la evaluación se recomienda ampliar la cantidad de consultas y cubrir distintos tipos de productos, marcas, tamaños y presentaciones. El conjunto de pruebas debería incluir coincidencias válidas con nombres muy diferentes y negativos difíciles, es decir, productos similares en vocabulario pero distintos en atributos relevantes. También sería conveniente etiquetar cada par de productos como equivalente o no equivalente y registrar los resultados en una matriz de confusión. Con esos datos se podrían calcular precisión y recall, además de contabilizar verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos.

Conclusión

El trabajo permitió explorar modelos de Hugging Face y aplicar un modelo de similitud semántica a la búsqueda de ofertas de Expensa House. En la muestra de 11 consultas, multilingual-e5-small obtuvo 8 aciertos, por encima de MiniLM y de la búsqueda literal. Sin embargo, también produjo falsos positivos, lo que demuestra que una puntuación alta de similitud no equivale necesariamente a una coincidencia comercial correcta. La principal conclusión es que la IA puede mejorar la recuperación de ofertas, pero debe integrarse con filtros y reglas de negocio, y evaluarse con un conjunto de pruebas más amplio.

La ejecución local resolvió la limitación de créditos de inferencia remota, mientras que las integraciones de voz y chatbot quedan como próximos pasos.

Los resultados deben interpretarse como preliminares hasta realizar una evaluación más completa y reproducible.

Fuentes y herramientas mencionadas

- Hugging Face: exploración y selección de modelos.
- Transformers: ejecución local del modelo.
- InferenceClient: prueba de inferencia remota.
- multilingual-e5-small y MiniLM multilingüe: comparación de similitud semántica.
- Whisper tiny: alternativa futura para reconocimiento de voz a texto.
- Qwen2.5 0.5B: alternativa futura para chatbot.

• Web Speech API, reconocimiento de Google y Gradio: tecnologías mencionadas en el estado actual de la función de voz.

7. Limitaciones y mejoras futuras

Entre las principales limitaciones se encuentran la dependencia de la calidad de los datos registrados, la necesidad de mantener actualizadas las ofertas y las restricciones de una sincronización basada en solicitudes.

Para avanzar hacia una solución más completa, se propone:

- Registrar movimientos de compra, apertura y consumo con fecha, cantidad y tipo de movimiento.
- Integrar un sistema de notificaciones de reposición.
- Incorporar fuentes verificables de precios y ofertas.
- Evaluar la detección de intenciones con un conjunto de pruebas más amplio.
- Comparar modelos candidatos y medir sus tiempos de inferencia.
- Desarrollar y validar un modelo predictivo utilizando un historial suficiente de movimientos.
- Incorporar autenticación, protección de datos y mecanismos de sincronización más robustos antes de un despliegue de producción.

8. Enlaces de entrega

En la versión definitiva de la monografía, esta sección debe contener únicamente los enlaces reales y comprobados:

- Aplicación publicada: http://127.0.0.1:8001/
- Repositorio del proyecto: griseldablanco78-blip/Seminario2026 at Proyecto_Integrador